



Vícevrstvá síť

Dokumentace projektu

Neuronové síť - PV021

pod vedením:

doc. RNDr. Tomáš Brázdil, Ph.D

xbrazdil@fi.muni.cz

Pavol Loffay, 374115

p.loffay@mail.muni.cz

Václav Blahut, 395963

blahut@mail.muni.cz

Jan Brandejs, 324130

324130@mail.muni.cz

Brno, 7. prosince, 2015

Úvod

Úlohou projektu bylo implementovat neuronovou síť v jazyku Java bez pomoci specializovaných knihoven pro neuronové sítě či matematické výpočty. Implementovanou síť jsme následně aplikovali na rozpoznávání rukou napsaných číslic z datového souboru MNIST¹. Po úspěšném rozpoznávání číslic jsme neuronovou síť použili na predikování měnových párů finančního trhu Forex.

Dokumentace je rozdělená na tři části. V první jsou popsány nejzajímavější části implementace. Druhá a třetí kapitola rozebírá použití námi implementované sítě na rozpoznávání číslic a predikci časových řad.

Implementace

Implementovali jsme vícevrstvou neuronovou síť se zpětnou propagací. Výstup ze zpětné propagace se následně použil pro gradientní sestup, který minimalizoval celkovou chybu pro danou tréninkovou množinu.

Jako implementační jazyk jsme zvolili Javu 8. Pro ulehčení kompilace a spouštění testů byl zvolen systém Apache Maven. K sdílení a dokumentaci zdrojových souborů jsme použili systém Git.

Rozhraní neuronové sítě bylo navrženo s ohledem na nejlepší nastavení sítě. Návrhový vzor stavitel nám umožnil elegantně instanciovat neuronovou síť se zvolenými parametry. Pokud bychom některý parametr vynechali, použila by se standardní hodnota. Následuje ukázka vytváření čtyřvrstvé neuronové sítě:

```
NeuralNetwork network = NeuralNetwork.newBuilder()
    .withGradientAlpha(0.05)
    .withGradientIterations(50)
    .withRegularize(true)
    .withRegularizeLambda(1.5)
    .withClassify(true)
    .withHypothesisFn(new Functions.Sigmoid())
    .withHypothesisDerivation(new Functions.SigmoidGradient())
    .withInputLayer(150)
    .addLayer(4)
    .addLayer(4)
    .addLastLayer(5);
```

Všimněte si, že je dokonce možné specifikovat použitou funkci a její derivaci.

Výpočet koeficientů sítě je možné poměrně jednoduše dělat maticovým způsobem. Jelikož jsme měli zakázané použít knihovny pro pracování s maticemi, byla implementována vlastní třída. Operace s touto třídou tvoří jádro výpočtů, proto bylo nevyhnutelné implementovat

¹ Dostupné na <http://yann.lecun.com/exdb/mnist/>

jednotkové testy na ověření správného chování matematických operací. Pokud bychom se rozhodli pro implementaci v jazyku C++, určitě bychom využili možnost přetěžování operátorů, toto však jazyk Java neposkytuje.

Rozpoznávání číslic

Rozpoznávání číslic je častou úlohou neuronových sítí. Proto jsme se i my rozhodli aplikovat naši síť na tento typ úlohy. Jako datovou množinu jsme použili MNIST, jak bylo zmíněno v úvodu dokumentace. Tento datový soubor obsahuje ručně psané číslice o velikosti 28x28 bodů. Tréninková množina má celkovou velikost 60 tisíc vzorků a testovací 10 tisíc.

Vzhledem k časové náročnosti procesu učení jsme se rozhodli ladit parametry sítě jen na podmnožině trénovací množiny v poměru 6000 trénovacích : 1000 testovacích obrázků. Se čtyřmi nejzajímavějšími parametry a architekturami sítě jsme pak pustili proces učení a testování na původních množinách s následujícími výsledky:

Architektura	Počet iterací	Rychlost učení	Správně
784 - 30 - 10	200	0.1	82.93%
784 - 100 - 10	200	0.1	88.51%
784 - 400 - 10	200	0.1	90.56%
784 - 800 - 10	100	0.1	89.8%

U posledních dvou experimentů dosáhla doba učení přibližně 40 hodin, dá se ale předpokládat, že např. zmíněná 800neuronová síť by s vyšším počtem iterací dosáhla ještě lepších výsledků.

Predikce časových řad

Strojové učení a neuronové sítě jsou současně častým nástrojem technické analýzy obchodních strategií finančních trhů. V naší práci jsme se pokusili vytvořit obchodovatelnou strategii na Forexu, což je mezinárodní obchodní systém pro směnu základních a vedlejších měnových párů a jedná se o největší a nejlikvidnější finanční trh.

Výběr a předzpracování dat

Jako datová množina byl zvolen měnový pár GBP/USD², v OHLC formátu na 1minutovém timefram. GBP/USD je jeden z hlavních měnových párů, je považován za volatilnější a lze na něm dosáhnout nejnižších spreadů (kolem 0,00007). Byla zahrnuta pouze data od 1.1.2015, tudíž na jedno minutovém timefram přibližně 350 000 údajů.

² Data byla získána pomocí SQ Tick Downloader, dostupného z <http://www.strategyquant.com/tickdownloader/>

Pro předzpracování dat byl vytvořen OHLCreader, který extrahoval pouze uzavírací hodnoty a z nich sestavil vstupní množinu v minutě t , $t + 1$, $t + 2$, ..., $t + 19$ a výstupní množinu pro minutu $t + 20$. Jelikož v použitých datech chybí data z víkendů, kdy se zpravidla neobchoduje, bylo potřeba zajistit, aby se v těchto vstupních sekvencích neobjevovaly tyto časové skoky, během nichž dochází i ke skokům v kurzu.

Data byla normalizována s použitím aktivační funkce, tj. logistickou sigmoidou, následující transformací:

$$\tilde{x}_i = \frac{1}{1 + \exp\left(-\frac{x_i - \bar{x}}{\sigma}\right)}$$


kde \bar{x} je střední hodnota souboru a σ je standardní odchylka. Získané predikce byly následně pro snadnější vyhodnocení denormalizovány inverzí této funkce.

Implementace predikce

Naši implementaci neuronové sítě pro klasifikaci ručně psaných číslic bylo pro predikci mírně upravit tak, aby namísto n hodnot výstupních neuronů odpovídajících n třídám při klasifikaci vracela pouze jednu hodnotu a to žádanou predikci vývoje kurzu. Chybou během učení byl rozdíl mezi predikovanou a reálnou normalizovanou hodnotou, pro ladění sítě a vyhodnocení jsme se pak řídili standardně používanou funkcí RMSE na denormalizovaných testovacích datech. Příklady výsledků spolu s parametry a architekturou sítě naleznete v tabulce:


Architektura	Train	Test	Délka úseku	Iter.	Rychlost učení	RMSE
20 - 30 - 1	280k	69k	20	400	1	0,00202
20 - 30 - 1	280k	69k	20	400	0,5	0,00208
10 - 5 - 1	10k	2k	10	400	1	0,00064
20 - 15 - 1	280k	69k	20	150	1	0,00199

Poslední ze zmíněných výsledků byl použit při backtestu obchodovatelnosti. Tento výsledek jsme také podrobili bližšímu porovnání výsledků predikce s reálnými daty:




V grafu vidíme predikci jako červenou a reálná data jako modrou linku. Ač jsou predikce místy o něco vyšší, než skutečná hodnota, všechny zásadní změny v reálných hodnotách jsou promítnuty i do predikcí.

V následujícím grafu jsou vyobrazeny změny kurzu. Je vidět, že predikované změny jsou sice o dost menší, než změny reálné, přesto tvarově odpovídají těm reálným, včetně těch zásadnějších, které jsou při rozhodování o nákupu nebo prodeji důležité.



Interpretace získaných výsledků

Na zmíněných výsledcích byla backtestem vyzkoušena jednoduchá obchodní strategie, která zahrnovala provedení 1minutových obchodů typu BUY či SELL podle nejvýraznějších predikcí sítě. Celkem bylo provedeno 274 obchodů typu SELL a 438 obchodů typu BUY, které při obchodování objemu 1 lotu (100 000 USD) dosáhly v období 1.10. – 10.12.2015 zisku 10 859 USD.



Jiné měnové páry

Pro zajímavost jsme provedli učení a test (již bez backtestu) se stejnými parametry a architekturou i na dalších šesti zajímavých měnových párech. Pro lepší interpretaci velikosti chyby je uvedena i střední hodnota kurzu daného měnového páru.

Pár	Train	Test	Stř. hodnota	RMSE
GBP-USD	280k	69k	1,53063	0,0019
EUR-USD	280k	64k	1,11092	0,0035
USD-CAD	280k	65k	1,27231	0,0104
USD-CHF	260k	63k	0,96017	0,0131
USD-JPY	280k	63k	121,020	0,17
AUD-USD	280k	69k	0,75396	0,0029
NZD-USD	280k	64k	0,96017	0,0015

Rozdělení práce

Následuje rozdělení práce mezi členy týmu:

- Pavol Loffay: implementace sítě a maticových operací, rozpoznávání číslic
- Jan Brandejs: výběr a předzpracování dat časových řad, obchodovací strategie
- Václav Blahut: úpravy implementace, experimenty s predikcí i klasifikací číslic

Závěr

Úspěšně jsme implementovali vícevrstvou síť se zpětnou propagací, kterou jsme otestovali na klasifikaci ručně psaných číslic a predikci časových řad měnových páru z finančního trhu Forex, kde se nám podařilo na základě predikovaných změn kurzu vytvořit výdělečnou obchodní strategii. Na obou úkolech by se dalo do budoucna pokračovat nejen dalším hledáním vhodnějších parametrů pro ještě lepší výsledky, ale u časových řad např. i použitím dat s nižší periodou a pracovat třeba i na úrovni jednotlivých ticků, tedy časových jednotek, v nichž se na burze obchoduje v reálném čase.

Metrika kódu

Počet souborů:	19
Počet řádků:	2332